

АНАЛИТИЧЕСКИЙ ОТЧЕТ О РЕЗУЛЬТАТАХ ИССЛЕДОВАНИЯ

Тема: Применение методов классического машинного обучения для моделирования биологической активности химических соединений.

Объем выборки: 1001 молекула, описанная физико-химическими дескрипторами.

1. Этап предобработки и очистки данных.

На начальном этапе был проведен комплексный разведочный анализ данных, позволивший полностью стабилизировать признаковое пространство и устранить математические аномалии исходного датасета:

- **логарифмирование целевых метрик:** исходные биологические показатели эффективности IC50, цитотоксичности CC50 и индекса селективности SI характеризовались экстремальным правосторонним сдвигом и аномальным разбросом, например для SI стандартное отклонение $std = 684.48$ превышало среднее в 9.5 раз. Десятичное логарифмирование успешно сжало шкалы и привело распределения к симметричному виду, для IC50 среднее 1.663 и медиана 1.668 практически совпали.

- **обработка пропусков:** было выявлено незначительное количество пропусков (по 3 пропуска в 12 сложных электронных дескрипторах). Ввиду малого объема (менее 0.3% от выборки), пропуски были заполнены медианными значениями колонок.

- **фильтрация признаков:** из датасета удален технический индекс Unnamed: 0. Проведена проверка на константные признаки, в ходе которой исключены 18 неинформативных столбцов с нулевой дисперсией.

- **обработка мультиколлинеарности:** написан алгоритм автоматической фильтрации избыточных связей по верхнему треугольнику матрицы корреляции Пирсона. Из каждой пары дескрипторов, со сверхвысокой зависимостью более 0.90, одна переменная удалялась.

- **масштабирование признаков:** для предотвращения смещения моделей и стабилизации данных было применено устойчивое к асимметрии робастное масштабирование (RobustScaler), выполненное строго после разделения выборки (в пропорции 70/30). За счет центрирования признаков по медиане и нормирования по межквартильному размаху вместо среднего значения и дисперсии, алгоритм успешно изолировал экстремальные значения фрагментных счетчиков, выровняв масштабы независимых переменных без потери уникальной структурной информации о сложных молекулах.

2. Регрессионное моделирование.

Метрика	Алгоритм машинного обучения	R^2	MSE	MAE
IC50	Линейная регрессия	0.3176	0.6038	0.6173
	Случайный лес (Random Forest)	0.4340	0.5008	0.5479
	Градиентный бустинг (HistGB)	0.4448	0.4913	0.5417
	Мета-модель	0.4397	0.4958	0.5430
CC50	Линейная регрессия	0.3389	0.2990	0.4244
	Случайный лес (Random Forest)	0.4087	0.2675	0.3763
	Градиентный бустинг (HistGB)	0.3686	0.2856	0.3810
	Мета-модель (Стекинг)	0.3976	0.2725	0.3733
SI	Линейная регрессия (Ridge)	0.1562	0.5044	0.5353
	Случайный лес (Random Forest)	0.2619	0.4413	0.4947
	Градиентный бустинг (HistGB)	0.2093	0.4727	0.5158

Для предсказания непрерывных биологических показателей молекул IC50, CC, SI были протестированы три базовых алгоритма и мета-модель (стекинг). Оценка проводилась на независимой тестовой выборке (30%), а масштабы признаков выравнивались с помощью RobustScaler.

Прогнозирование эффективности IC50: лидер - Градиентный бустинг $R^2 = 0.4448$, MSE = 0.4913. Линейная регрессия показала худший результат $R^2 = 0.3176$, так как зависимость активности от структуры нелинейна. Ансамбли на

основе деревьев решений Случайный лес с $R^2 = 0.4340$ и Градиентный бустинг успешно справились со спецификой химических данных. Мета-модель стекинга объединила их прогнозы и выдала сбалансированный результат $R^2 = 0.4397$, защитив систему от переобучения.

Прогнозирование эффективности CC50: лидер - Случайный лес $R^2 = 0.4087$, $MSE = 0.2675$. Механизмы клеточной токсичности крайне сложны и разнообразны. В этих условиях последовательный бустинг $R^2 = 0.3686$ частично переобучился на шумах, а стратегия усреднения независимых деревьев в Случайном лесе показала лучшую обобщающую способность. Мета-модель стекинга сработала эффективно, зафиксировав высокую точность $R^2 = 0.3976$ и минимальную ошибку прогноза $MSE = 0.2725$.

Прогнозирование эффективности SI: лидер - Случайный лес $R^2 = 0.2619$, $MSE = 0.4413$. Прямое непрерывное предсказание терапевтического окна по структуре молекул оказалось самой сложной задачей. Резкое падение точности всех моделей связано с тем, что индекс селективности рассчитывается как отношение безопасности к эффективности. Математическое объединение двух разных биологических процессов удвоило уровень шума в данных. Этот результат доказал, что для работы с комплексным показателем SI гораздо эффективнее использовать задачу бинарной классификации.

3. Классификационное моделирование.

Метрика	Алгоритм машинного обучения	Accuracy	F1-score	ROC-AUC
IC50 по медиане	Логистическая регрессия	0.6877	0.7025	0.7318
	Случайный лес	0.7143	0.7394	0.7957
	Градиентный бустинг	0.7276	0.7469	0.8076
CC50 по медиане	Линейная классификация (Логистическая регрессия)	0.7276	0.7389	0.7976
	Случайный лес	0.7375	0.7569	0.8276
	Градиентный бустинг	0.6777	0.7052	0.8039
SI по медиане	Логистическая регрессия	0.6445	0.6397	0.6617

	Случайный лес	0.6877	0.6690	0.7317
	Градиентный бустинг	0.6711	0.6452	0.7024
	Метод каскадного голосования	0.8405	0.3684	—
SI > 8	Прямая классификация (Случайный лес)	0.7176	0.7043	0.7343
	Каскадный отбор (Случайный лес)	0.5503	0.5291	—

Для повышения надежности отбора молекул непрерывные биологические показатели были переведены в формат бинарной классификации. Качество построенных моделей оценивалось по трем классическим критериям: доле правильных ответов (Accuracy), сбалансированной точности и полноте (F1-score), а также по общей разделительной способности (ROC-AUC).

Классификация эффективности (IC50 по медиане): лидер - Градиентный бустинг (Accuracy = 0.7276, ROC-AUC = 0.8076). Разделение выборки по медиане сформировало сбалансированные классы. Высокий показатель площади под ROC-кривой (> 0.80) подтверждает применимость бустинга для качественного ранжирования активных соединений.

Классификация безопасности (CC50 по медиане): лидер - Случайный лес (Accuracy = 0.7375, ROC-AUC = 0.8276). В задаче предсказания клеточной токсичности Случайный лес показал максимальную обобщающую способность, обеспечив наилучший баланс точности и полноты (F1-score = 0.7569).

Классификация терапевтического окна (SI по медиане): лидер - Метод каскадного голосования (Accuracy = 0.8405). Прямая классификация комплексного индекса селективности SI уступает изолированным задачам (лучший результат у Случайного леса составил Accuracy = 0.6877). Разделение общей задачи на двух независимых «экспертов» (один оценивал эффективность, второй — безопасность) с вынесением решения по строгому правилу «И» привело к увеличению точности. Каскадный подход обеспечил лучший показатель (Accuracy 0.8405) во всем исследовании.

Классификация по практическому порогу (SI > 8): лидер - Прямая классификация на базе Случайного леса (Accuracy = 0.7176, F1-score = 0.7043, ROC-AUC = 0.7343). Переход на жесткую фармакологическую границу отбора (SI > 8) сместил баланс классов в сторону неактивных молекул. В этих условиях прямой запуск Случайного леса оказался эффективнее каскадного отбора (Accuracy = 0.5503).

4. Заключение и рекомендации.

Вывод о применимости: Классическое машинное обучение полностью применимо для первичного скрининга молекул. Линейные методы имеют низкую эффективность. Ансамбли на основе деревьев решений являются оптимальным технологическим выбором, демонстрируя точность классификации до 73–74% и качество ранжирования молекул ROC-AUC до 0.81–0.83.

Практическая ценность: В фармакологии вероятность случайного нахождения активного вещества составляет всего 1–2%. Разработанная модель Случайного леса для порога $SI > 8$ способна поднять точность целевого отбора перспективных соединений (Precision) до 62%, что позволяет кратно снизить экономические издержки и сократить время проведения реального химического синтеза.

Рекомендации по улучшению: Для преодоления текущих барьеров точности в будущих исследованиях рекомендуется:

- Перейти от общих характеристик молекулы (таких как вес или площадь поверхности) к составлению её точной «цифровой карты» (молекулярных фингерпринтов).
- Внедрить алгоритмы калибровки вероятностей (CalibratedClassifierCV) для точной настройки порогов отсечения бустинга.
- Использовать методы мягкого ансамблирования (Soft Voting) для объединения прогнозов Случайного леса и Логистической регрессии.